

1. Naziv teme

Semantička segmentacija anomalija na poljoprivrednim površinama korišćenjem konvolucionih neuronskih mreža

2. Definicija problema

Savremena poljoprivreda sve više koristi tehnologiju sa ciljem povećanja efikasnosti proizvodnje, smanjenja gubitaka i optimizacije resursa. Jedan od značajnih izazova u preciznoj poljoprivredi jeste pravovremeno otkrivanje problema na obradivim površinama. Takvi problemi mogu imati direktan uticaj na kvalitet useva i ukupne prinose, zbog čega je njihovo rano uočavanje od velikog značaja.

U praksi se identifikacija nepravilnosti na parcelama najčešće vrši ručnim obilaskom i vizuelnom analizom stanja useva. Ovakav pristup zahteva mnogo vremena, može biti skup i podložan je subjektivnim procenama i ljudskoj grešci. Razvojem dronova omogućeno je brzo snimanje velikih poljoprivrednih površina iz vazduha, ali ručna analiza tako prikupljenih snimaka i dalje predstavlja spor i zahtevan proces.

Cilj ovog projekta jeste **automatska klasifikacija svih piksela slike poljoprivredne parcele u jednu od kategorija anomalija ili u kategoriju zdravog useva**. Problem se formuliše kao zadatak **semantičke segmentacije**, pri čemu model za svaki pojedinačni piksel određuje odgovarajuću klasu.

Anomalije koje se detektuju su:

- Dvostruka sadnja
- Preskočena sadnja
- Zadržavanje vode
- Vodeni tok
- Pojava korova

3. Skup podataka

Za realizaciju projekta koristiće se skup podataka **Agriculture Vision**, javno dostupan na sledećem linku: <https://huggingface.co/datasets/shi-labs/Agriculture-Vision>

Osnovne karakteristike skupa podataka su:

- **Broj instanci:** 21.061
 - **Trening:** 12.901
 - **Validacija:** 4.431
 - **Test:** 3.729
- **Rezolucija slike:** 512 × 512 px

Skup podataka sadrži realne snimke poljoprivrednih površina iz vazduha i pogodan je za rešavanje problema semantičke segmentacije, jer pored ulaznih slika sadrži i odgovarajuće anotacije za različite tipove anomalija.

Svaka instanca u skupu podataka sadrži sledeće attribute:

- **RGB slika** - Trokanalni snimak parcele - najznačajniji atribut, nosi sve vizuelne informacije.
- **NIR kanal** - Infracrveni snimak - dodatna informacija o stanju vegetacije.
- **Maska validnog regiona** - Označava piksele validne za evaluaciju.
- **Anotacione maske** - Binarne maske za svaku klasu anomalije.

RGB slika predstavlja osnovni ulaz za model, jer sadrži najvažnije vizuelne informacije potrebne za prepoznavanje anomalija. Pored toga, NIR kanal može pružiti dodatne informacije o stanju vegetacije. Maska validnog regiona definiše delove slike koji se uzimaju u obzir prilikom evaluacije, dok anotacione maske predstavljaju ručno definisane binarne oznake za svaku pojedinačnu klasu anomalije.


Ciljno obeležje u ovom projektu predstavlja **maska segmentacije**, odnosno oznaka klase za svaki piksel slike.

Klase u okviru projekta su:

- pozadina(normalni prinosi)
- senka oblaka
- dvostruka sadnja
- preskočena sadnja
- stajaća voda
- vodeni tok
- pojava korova

Tokom pripreme podataka, pojedinačne binarne maske biće spojene u jednu jedinstvenu masku segmentacije, pri čemu će svakom pikselu biti dodeljena odgovarajuća klasa. Na taj način formira se finalno ciljno obeležje koje model treba da nauči da predviđa.

Primer iz dataset-a:



4. Metodologija

Problem segmentacije anomalija na poljoprivrednim površinama biće rešen primenom metoda dubokog učenja, odnosno modela prilagođenih zadacima semantičke segmentacije. Osnovna ideja jeste da model na osnovu ulazne slike nauči da razlikuje zdrave delove useva od regiona koji pripadaju određenim anomalijama.

Metodologija obuhvata faze preprocesiranja podataka, augmentacije, izbora i implementacije modela, treniranja i evaluacije rezultata.

4.1 Preprocesiranje

Pre početka treniranja biće sprovedena analiza podataka radi boljeg razumevanja strukture skupa podataka i zastupljenosti pojedinih klasa.

U okviru preprocesiranja biće sprovedeni sledeći koraci:

- Spajanje binarnih maski u jedinstvenu masku segmentacije
- Normalizacija vrednosti piksela
- Analiza distribucije klasa

Spajanje maski omogućava formiranje jednog izlaza pogodnog za višeklasnu segmentaciju. Normalizacija vrednosti piksela doprinosi stabilnijem treniranju modela, dok analiza distribucije klasa omogućava bolje razumevanje disbalansa između različitih kategorija.

4.2 Augmentacija

Kako bi se povećala raznovrsnost trening skupa i poboljšala sposobnost generalizacije modela, koristiće se augmentacija podataka. Ovim postupkom simuliraju se različite realne promene koje se mogu javiti u snimcima iz vazduha, bez potrebe za dodatnim prikupljanjem i anotiranjem podataka.

Planirane tehnike augmentacije su:

- Horizontalno/vertikalno preslikavanje
- Rotacija
- Promena svetline i kontrasta
- Dodavanje šuma

Primena ovih transformacija treba da doprinese većoj robusnosti modela i boljem ponašanju na neviđenim podacima.

4.3 Modeli

U okviru projekta biće razmotreno više modela kako bi se izvršilo poređenje performansi i odredilo najpogodnije rešenje za dati problem.

U-Net + ResNet-50

Encoder-decoder arhitektura; ResNet-50 pretreniran na ImageNet-u služi kao enkoder - polazni (baseline) model.

Ovaj model predstavlja početnu tačku eksperimentalnog dela rada. U-Net je jedna od najzastupljenijih arhitektura za semantičku segmentaciju, jer omogućava efikasno kombinovanje kontekstualnih informacija i detalja visoke rezolucije. Upotreba pretreniranog ResNet-50 enkodera doprinosi bržem učenju i boljoj generalizaciji modela.

U-Net + EfficientNet-B3

Alternativni enkoder sa manjim brojem parametara, optimizovan za bolju računsku efikasnost uz sličnu tačnost.

Ovaj model omogućava poređenje sa efikasnijim enkoderom, kako bi se procenilo da li je moguće postići slične performanse uz manju računsku složenost.

DINO v3

Napredna arhitektura zasnovana na Vision Transformer (ViT) modelima koja omogućava izuzetno preciznu ekstrakciju obeležja na nivou piksela.

Uvođenjem ovog modela omogućava se poređenje konvolucionih pristupa sa savremenim transformer arhitekturama, sa ciljem procene njihovog doprinosa kvalitetu segmentacije.

4.4 Treniranje

Treniranje modela biće sprovedeno korišćenjem odgovarajućih tehnika optimizacije i funkcija gubitka kako bi se obezbedilo stabilno učenje i dobra generalizacija.

Optimizator:

- **AdamW** — Adam sa weight decay regularizacijom za bolju generalizaciju.

AdamW će biti korišćen zbog svoje efikasnosti u treniranju dubokih modela i zbog mogućnosti bolje kontrole regularizacije.


Scheduler:

- **Cosine Annealing** — postepeno smanjuje learning rate prateći kosinusnu funkciju.

Ovakav pristup omogućava postepeno i kontrolisano smanjivanje learning rate vrednosti tokom treniranja, što doprinosi stabilnijem približavanju optimumu.

Za funkcije gubitaka koristimo:

- **Cross-Entropy Loss** - Meri razliku između predviđene distribucije verovatnoća i stvarne klase za svaki piksel.
- **Dice Loss** - Direktno optimizuje preklapanje predviđene i stvarne maske - ublažava problem disbalansa klasa.

$$\text{Dice coefficient} = \frac{2 \times \text{area of overlapped (green)}}{\text{total area (green)}} =$$


The diagram illustrates the Dice coefficient calculation. It shows a blue 'predicted' mask and a red 'ground truth' mask overlapping in a green area. Below, the total area of the predicted mask (blue) and the ground truth mask (red) is shown, with the overlapping green area counted twice.

Kombinovanjem ove dve funkcije gubitka nastoji se postići bolja ravnoteža između klasifikacione tačnosti i kvaliteta segmentacije, posebno u uslovima izraženog disbalansa klasa.

4.5 Plan eksperimenata

Eksperimentalni deo projekta biće organizovan kroz više koraka, pri čemu će se postepeno uvoditi izmene i pratiti njihov uticaj na performanse modela.

Plan eksperimenata obuhvata:

1. Bazni model — U-Net + ResNet-50, bez augmentacija
2. Uvođenje augmentacija i merenje napretka
3. Podešavanje funkcije gubitka (kombinovanje CE i Dice Loss) i težina klasa
4. Zamena enkodera — prelazak na EfficientNet-B3
5. Prelazak na DINO v3 i poređenje performansi
6. Finalna analiza rezultata

U završnoj fazi rada biće sprovedena detaljna analiza rezultata, uključujući poređenje performansi različitih modela i razmatranje tipičnih grešaka u predikciji.

5. Način evaluacije

Za evaluaciju ćemo koristiti:

MIoU - Srednja vrednost Intersection over Union po svim klasama — ravnopravno tretira i slabo zastupljene klase.

Ova metrika je pogodna za problem semantičke segmentacije jer meri stepen preklapanja između predviđene i stvarne maske za svaku klasu posebno, a zatim računa njihovu srednju vrednost. Na taj način omogućava objektivnu procenu uspešnosti modela i kod klasa koje su manje zastupljene u skupu podataka.

6. Tehnologije

Za izradu projekta, biće koristene sledeće tehnologije:

- **Python** – Osnovni programski jezik.
- **PyTorch** - Glavni framework za implementaciju i treniranje modela dubokog učenja.
- **segmentation_models_pytorch** - Biblioteka sa gotovim implementacijama U-Net arhitekture i enkoderima.
- **HuggingFace Transformers / timm** - Biblioteke za učitavanje i rad sa DINO v3 i Vision Transformer modelima.
- **Albumentations** - Efikasna augmentacija slika.
- **OpenCV** - Učitavanje i preprocesiranje slika.

- **NumPy** - Numeričke operacije nad tenzorima i maskama.
- **Kaggle / Google Colab** - Okruženje sa besplatnim GPU resursima za treniranje.

Navedene tehnologije omogućavaju realizaciju kompletnog sistema, od učitavanja i obrade podataka, preko implementacije i treniranja modela, do evaluacije i analize rezultata.

7. Primeri

Postoji više javno dostupnih rešenja koja se bave problemom segmentacije anomalija na poljoprivrednim površinama korišćenjem Agriculture Vision skupa podataka, a neka od njih su:

- **Agriculture-Vision zvanični repo** - <https://github.com/SHI-Labs/Agriculture-Vision>
- **DINO zvanični repozitorijum** - <https://github.com/facebookresearch/dinov3>
- **segmentation_models_pytorch** - https://github.com/qubvel/segmentation_models.pytorch

8. Relevantna literatura

1. Chiu et al. — Agriculture-Vision: A Large Aerial Image Database for Agricultural Pattern Analysis — <https://arxiv.org/abs/2001.01306>
2. He et al. — Deep Residual Learning for Image Recognition — <https://arxiv.org/abs/1512.03385>
3. Oquab et al. — DINO v3: Learning Robust Visual Features without Supervision — <https://arxiv.org/abs/2304.07193>